

Papel original

# Identificación de fenotipos conductuales de soledad y relaciones sociales

## Aislamiento con detección pasiva: análisis estadístico, minería de datos y aprendizaje automático de datos de teléfonos inteligentes y Fitbit

Afsaneh Doryab<sup>1,2</sup>, PhD; Daniella K Villalba<sup>3</sup>, Doctor; Prerna Chikeral<sup>1</sup>, Maestría en Ciencias; Janine M. Dutcher<sup>3</sup>, Doctor; Miguel Dummina<sup>4</sup>, Licenciatura en Letras; Sheldon Cohen<sup>3</sup>, Doctor; Kasey Creswell<sup>3</sup>, Doctor; Jennifer Mankoff<sup>5</sup>, Doctor; Juan D. Creswell<sup>3</sup>, Doctor; Anind K Dey<sup>6</sup>, Doctor

<sup>1</sup> Facultad de Ciencias de la Computación, Universidad Carnegie Mellon, Pittsburgh, PA, Estados Unidos

<sup>2</sup> Escuela de Ingeniería y Ciencias Aplicadas, Universidad de Virginia, Charlottesville, VA, Estados Unidos

<sup>3</sup> Departamento de Psicología, Universidad Carnegie Mellon, Pittsburgh, PA, Estados Unidos

<sup>4</sup> Escuela de Educación, Universidad de Pittsburgh, Pittsburgh, PA, Estados Unidos

<sup>5</sup> Escuela Paul G Allen de Ciencias de la Computación e Ingeniería, Universidad de Washington, Seattle, WA, Estados Unidos

<sup>6</sup> Escuela de Información, Universidad de Washington, Seattle, WA, Estados Unidos

Autor para correspondencia:

Afsaneh Doryab, PhD

Escuela de Ciencias de la

Computación Universidad Carnegie Mellon 5000 Forbes

Avenue Pittsburgh, PA, 15213 Estados

Unidos Teléfono: 1

4123045320 Correo electrónico: [adoryab@gmail.com](mailto:adoryab@gmail.com)

## Abstracto

**Antecedentes:** Los sentimientos de soledad están asociados con una mala salud física y mental. La detección de la soledad mediante sensores pasivos en dispositivos personales puede conducir al desarrollo de intervenciones destinadas a disminuir las tasas de soledad.

**Objetivo:** El objetivo de este estudio fue explorar el potencial del uso de sensores pasivos para inferir niveles de soledad e identificar los patrones de comportamiento correspondientes.

**Métodos:** Se recopilaron datos de teléfonos inteligentes y Fitbits (Flex 2) de 160 estudiantes universitarios durante un semestre. Los participantes completaron el cuestionario de soledad de la Universidad de California en Los Ángeles (UCLA) al principio y al final del semestre.

Para fines de clasificación, las puntuaciones se clasificaron en niveles de soledad altos (puntuación del cuestionario > 40) y bajos ( $\leq 40$ ).

Se extrajeron funciones diarias de ambos dispositivos para capturar la actividad y la movilidad, la comunicación y el uso del teléfono, y los comportamientos de sueño. Luego, las características se promediaron para generar características a nivel semestral. Utilizamos 3 métodos analíticos: (1) análisis estadístico para proporcionar una descripción general de la soledad en estudiantes universitarios, (2) minería de datos utilizando el algoritmo Apriori para extraer patrones de comportamiento asociados con la soledad y (3) clasificación de aprendizaje automático para inferir el nivel de soledad. La soledad y el cambio en los niveles de soledad utilizando un conjunto de algoritmos de regresión logística y aumento de gradiente con selección de características en una forma de validación cruzada que deja a un estudiante fuera.

**Resultados:** La puntuación promedio de soledad de las encuestas previas y posteriores fue superior a 43 (DE antes de la encuesta 9,4 y DE 10,4 después de la encuesta), y la mayoría de los participantes cayeron en la categoría de soledad alta (puntuaciones superiores a 40) con un 63,8% (102/160) en la encuesta preencuesta y 58,8% (94/160) en la posencuesta. Se observaron puntuaciones superiores a 1 desviación estándar por encima de la media en el 12,5% (20/160) de los participantes tanto en las puntuaciones previas como posteriores a la encuesta. La mayoría de las puntuaciones, sin embargo, cayeron entre 1 desviación estándar por debajo y por encima de la media (pre=66,9% [107/160] y post=73,1% [117/160]). Nuestro proceso de aprendizaje automático logró una precisión del 80,2 % en la detección del nivel binario de soledad y una precisión del 88,4 % en la detección de cambios en el nivel de soledad.

La exploración de asociaciones entre las características de comportamiento seleccionadas por el clasificador y la soledad indicó que, en comparación con los estudiantes con baja soledad, los estudiantes con altos niveles de soledad pasaban menos tiempo fuera del campus durante las tardes los fines de semana y pasaban menos tiempo en lugares para eventos sociales en el tarde entre semana (apoyo=17% y confianza=92%).

El análisis también indicó que una mayor actividad y un comportamiento menos sedentario, especialmente por la noche, se asociaron con una disminución de los niveles de soledad desde el inicio del semestre hasta el final del mismo (apoyo=31% y confianza=92%).

Conclusiones: La detección pasiva tiene el potencial de detectar la soledad en estudiantes universitarios e identificar los patrones de comportamiento asociados. Estos hallazgos resaltan las oportunidades de intervención a través de la tecnología móvil para reducir el impacto de la soledad en la salud y el bienestar de las personas.

(JMIR Mhealth Uhealth 2019;7(7):e13209) doi: [10.2196/13209](https://doi.org/10.2196/13209)

## PALABRAS CLAVE

salud móvil; soledad; aprendizaje automático; análisis de datos estadísticos; procesamiento de datos; fenotipado digital

## Introducción

### Antecedentes La

soledad en los Estados Unidos y en todo el mundo está aumentando a un nivel epidémico [1]. Según el último Informe del Índice de Soledad de EE. UU. [2], casi la mitad de los estadounidenses reportan altos niveles de soledad con una puntuación promedio de soledad de 43,9. De los encuestados, el 46% informó que a veces o siempre se sentía solo y el 47% informó que se sentía separado de los demás. Los niveles más altos de soledad se encontraron entre los adultos jóvenes de 18 a 22 años que tenían una puntuación promedio de soledad de 48,3. La soledad se define como una experiencia emocional negativa causada por una discrepancia entre el contacto social deseado y el logrado [3] o el aislamiento social percibido [1,4]. A diferencia de la soledad, que es un estado de estar físicamente solo, la soledad se relaciona con un sentimiento subjetivo y puede ocurrir en individuos a pesar de tener relaciones sociales o estar rodeados de otras personas [5,6].

Las relaciones sociales están estrechamente ligadas a la salud de las personas y la falta de conexión social tiene un impacto adverso en la salud y el bienestar [7,8]. En una revisión sistemática y un metanálisis histórico de 148 estudios que examinaban las relaciones sociales y el riesgo de mortalidad, Holt-Lunstad et al [9] encontraron que los adultos mayores con relaciones sociales más sólidas tenían un 50% más de probabilidad de supervivencia que aquellos con relaciones sociales más débiles.

Investigaciones posteriores de este grupo encontraron que el aislamiento social, la soledad y vivir solo constituían mayores riesgos de mortalidad que la obesidad [10]. Es importante destacar que la soledad también se ha asociado con un mayor riesgo de desarrollar depresión y otros problemas de salud mental [10].

Dada la importancia de la soledad en los resultados de salud y bienestar, el objetivo de este estudio fue detectar y comprender la soledad a través de señales de comportamiento recopiladas de teléfonos inteligentes y dispositivos portátiles. El uso generalizado de dispositivos móviles brinda la oportunidad de recopilar pasivamente rastros de comportamiento diarios relacionados con la salud mental y el bienestar durante un largo período de tiempo. Estábamos interesados en comprender (1) qué tan bien podíamos detectar si alguien se sentía solo analizando sus señales de comportamiento digitales diarias y (2) qué patrones de comportamiento estaban asociados con la soledad.

### Trabajo relacionado

Pulekar et al [11] estudiaron la primera pregunta en un pequeño estudio con 9 estudiantes universitarios durante 2 semanas. Se analizaron registros de datos de interacciones sociales, comunicación y actividad de teléfonos inteligentes para detectar la soledad y su relación con los rasgos de personalidad. El estudio reporta una precisión del 90% en la clasificación de la soledad utilizando el

características de los teléfonos inteligentes que se correlacionaron principalmente con la puntuación de soledad. Sin embargo, el pequeño tamaño de la muestra, la corta duración de la fase de recopilación de datos y la falta de detalles en el enfoque de aprendizaje automático, especialmente en la evaluación de la clasificación, hacen que los resultados sean difíciles de generalizar y desear. Sánchez et al [12] utilizaron el aprendizaje automático para inferir el nivel de soledad en 12 adultos mayores que utilizaron una aplicación móvil durante una semana. Los registros de llamadas y las coordenadas del sistema de posicionamiento global (GPS) se recopilaron de los teléfonos. Se construyeron un total de 4 modelos de soledad familiar, soledad conyugal, soledad social y crisis existencial con una precisión reportada del 91,6%, 83,3%, 66,6% y 83,3%, respectivamente. Sin embargo, al igual que los resultados del estudio de Pulekar et al, estos resultados pueden no generalizarse debido a la pequeña muestra y la corta duración de la recopilación de datos.

Algunos estudios han explorado la segunda pregunta utilizando análisis de correlación para comprender las relaciones entre señales de comportamiento individuales, como el nivel de actividad física, la movilidad, las interacciones sociales y la soledad [13-15]. Wang et al [14] analizaron datos de teléfonos inteligentes recopilados de 40 estudiantes durante un semestre de primavera y encontraron correlaciones negativas entre la soledad y la duración de la actividad diurna y nocturna, la distancia recorrida y la movilidad interior durante el día. Un estudio relacionado del mismo grupo encontró correlaciones estadísticamente significativas ( $P < 0,01$ ) entre las actividades cinestésicas y el cambio en la soledad, pero ninguna relación entre la soledad y la duración del sueño, la actividad geoespacial o la duración del habla [13]. Gao et al [15] descubrieron que las personas con niveles más altos de soledad hacían o recibían menos llamadas telefónicas y usaban ciertos tipos de aplicaciones, como salud y fitness, redes sociales y navegación web, con más frecuencia que aquellos con niveles bajos de soledad. Nuestro enfoque de minería de datos, además de proporcionar características de comportamiento similares a las informadas por Wang et al [14], presenta un método innovador para extraer los patrones de comportamiento combinados en nuestra población participante. Por ejemplo, podemos observar que, en comparación con los estudiantes con un nivel bajo de soledad, los estudiantes con un nivel alto de soledad desbloquean sus teléfonos en diferentes segmentos de tiempo durante los fines de semana, pasan menos tiempo fuera del campus durante las horas de la tarde los fines de semana y socializan menos durante horario vespertino de lunes a viernes. Hasta donde sabemos, este estudio introduce, por primera vez, un enfoque para extraer patrones de comportamiento combinados a través de la minería de datos y sus asociaciones con un resultado de salud mental, como la soledad, a partir de datos de detección pasiva.

## Métodos

### Reclutamiento y recopilación de datos

La recopilación de datos se realizó como parte de un estudio en todo el campus de una universidad de investigación estadounidense en el estado de Pensilvania para evaluar la salud y el bienestar de los estudiantes. Los participantes eran estudiantes de primer año de pregrado reclutados a través de anuncios en listas de correo de estudiantes y grupos de Facebook. Se asignó un documento de identidad (ID) a cada participante y los documentos que conectaban la identificación con el nombre y los datos demográficos del participante se mantuvieron separados. Los datos del teléfono eran anónimos y sólo identificables a través del ID del dispositivo del participante. Todos los procedimientos de recopilación de datos en este estudio fueron aprobados por la Junta de Revisión Institucional de la universidad (IRB: STUDY2016\_00000421), incluida la recopilación de datos de ubicación. Se invitó a los estudiantes a una cita inicial en nuestro laboratorio para evaluar su elegibilidad, proporcionar su consentimiento informado por escrito para participar en el estudio y permitimos recopilar sus datos. En esta cita, los participantes descargaron la aplicación de recopilación de datos AWARE de código abierto [16] que se desarrolló en nuestro laboratorio para rastrear los datos de los sensores desde sus propios teléfonos inteligentes Android o iOS y recibieron un Fitbit Flex 2 para rastrear los pasos y el sueño. Posteriormente, los estudiantes completaron cuestionarios basados en la web para una evaluación inicial de su salud y bienestar. Al final del estudio, los estudiantes completaron los mismos cuestionarios para las mediciones posteriores. De los 188 estudiantes universitarios de primer año matriculados inicialmente, 160 (61% mujeres, 57% asiáticos, 34% blancos, 9% hispanos y 5% negros) completaron todas las encuestas previas y posteriores al semestre. Los participantes fueron informados sobre el propósito del estudio durante la sesión de cita inicial. No hubo engaño ni omisión de los objetivos del estudio para los participantes.

Los datos se recopilaron pasivamente desde sus teléfonos inteligentes y dispositivos Fitbit y se registraron continuamente durante 16 semanas del estudio (1 semestre que fue el segundo semestre de los participantes en la universidad). El marco AWARE [17] es una aplicación de recopilación de datos de código abierto con infraestructura de red y backend de soporte, que recopila datos de sensores de manera discreta desde los teléfonos inteligentes de los estudiantes. Es compatible con las plataformas Android e iOS y se puede descargar desde las tiendas App y Play. AWARE nos permitió registrar direcciones Bluetooth cercanas, Wi-Fi, ubicación, uso del teléfono (es decir, cuando el estado de la pantalla cambió a encendido o apagado y bloqueado o desbloqueado) y registros de llamadas y mensajes de texto del servicio de mensajes cortos (SMS). Se pidió a los participantes que mantuvieran encendidos su Bluetooth y Wi-Fi durante el estudio. Para evaluar las llamadas a contactos cercanos, pedimos a los participantes que proporcionaran los números de teléfono de familiares, amigos en el campus y amigos fuera del campus con los que contactan con más frecuencia. También utilizamos un complemento de conversación para AWARE (igual que el utilizado por Wang et al [14]), que realiza inferencias de audio, como silencio, voz, ruido o desconocido. Además, equipamos a los participantes con un rastreador de actividad portátil Fitbit Flex 2 que registra la cantidad de pasos dados y el estado del sueño (dormido, despierto, inquieto o desconocido). Se indicó a los estudiantes que usaran el dispositivo en su mano no dominante. Elegimos basado en Flex 2

en una combinación de factores que incluyen simplicidad, impermeabilidad, duración de la batería y precio. Fitbit Flex ha demostrado tener una validez moderada para realizar un seguimiento de actividades en comparación con ActiGraph [16]. Las llamadas y el uso del teléfono fueron flujos de sensores basados en eventos, mientras que Bluetooth, Wi-Fi, ubicación, sueño y pasos se muestrearon como series temporales. Estos flujos de datos de series temporales se muestrearon a diferentes velocidades debido a las capacidades del hardware utilizado. Las coordenadas de Bluetooth y ubicación se recopilaron en 1 muestra cada 10 minutos, el sueño en 1 muestra por minuto y los pasos en 1 muestra cada 5 minutos. Los datos de AWARE fueron desidentificados y transferidos automáticamente a través de Wi-Fi a nuestro servidor backend de forma regular, y los datos del Fitbit portátil se recuperaron utilizando la interfaz de programación de aplicaciones (API) de Fitbit al final del estudio. Se pidió a los participantes que mantuvieran su teléfono y Fitbit cargados y con ellos en todo momento.

### Procesamiento de datos de encuestas

Para evaluar la soledad, utilizamos la escala de soledad revisada de la Universidad de California, Los Ángeles (UCLA), una medida bien validada y de uso común de los sentimientos generales de soledad [18]. Los participantes calificaron cada una de las 20 preguntas (cuadro de texto 1) utilizando una escala de 1 (nunca) a 4 (siempre). Se puntuaron de forma inversa un total de 9 ítems antes de sumarlos para crear una puntuación total. Las puntuaciones totales de soledad oscilaron entre 20 y 80, y las puntuaciones más altas indicaban niveles más altos de soledad. Como no existe un límite estándar para las puntuaciones de soledad en la literatura, cada estudio ha creado categorizaciones arbitrarias que incluyen las categorías propuestas en el estudio de Cacioppo et al [1]: La soledad alta se define como una puntuación de 44 o más, la soledad baja se define como una puntuación de 44 o más. menos de 28, y las puntuaciones entre 33 y 39 representan la mitad del espectro. Aunque pudimos adaptar estas categorías, nuestro objetivo era hacer una clasificación binaria para detectar el nivel de soledad, lo que requirió dividir las puntuaciones de soledad en 2 categorías. También queríamos crear puntuaciones de corte que fueran independientes de la distribución de la población pero que representaran indicadores conceptuales de soledad.

Por lo tanto, como las opciones de respuesta proporcionadas fueron 1=nunca, 2=rara vez, 3=a veces y 4=a menudo, determinamos que las puntuaciones de 40 o menos indicaban que los participantes rara vez o nunca experimentaban soledad y las puntuaciones de 41 o más lo harían. indicar que al menos a veces experimenta soledad (un participante que respondió raramente (puntuación = 2) a las 20 preguntas tendría una puntuación total de 40, lo que sugiere que 40 indica que el participante rara vez experimenta soledad). Por lo tanto, utilizamos 40 como punto de corte donde las puntuaciones de 40 y menos se clasificaron como soledad no a baja y las puntuaciones superiores a 40 se clasificaron como soledad de moderada a alta. Para simplificar, nos referimos a la categoría de soledad no a baja como soledad baja y a la categoría de soledad moderada a alta como soledad alta. Estas categorías se utilizaron como etiquetas de verdad fundamental en nuestro proceso de aprendizaje automático para inferir el nivel de soledad. Aunque esta elección puede replicarse en otros estudios similares, se deben realizar más análisis de sensibilidad para determinar el punto de corte óptimo para la escala UCLA.

Cuadro de texto 1. Lista de preguntas utilizadas en la escala de soledad de la Universidad de California, Los Ángeles (las preguntas marcadas con R se calificaron al revés).

R1. ¿Con qué frecuencia sientes que estás en sintonía con las personas que te rodean?
2. ¿Con qué frecuencia sientes que te falta compañía?
3. ¿Con qué frecuencia sientes que no hay nadie a quien recurrir?
4. ¿Con qué frecuencia te sientes solo?
R5. ¿Con qué frecuencia te sientes parte de un grupo de amigos?
R6. ¿Con qué frecuencia sientes que tienes mucho en común con las personas que te rodean?
7. ¿Con qué frecuencia sientes que ya no estás cerca de nadie?
8. ¿Con qué frecuencia sientes que quienes te rodean no comparten tus intereses e ideas?
R9. ¿Con qué frecuencia te sientes extrovertido y amigable?
R10. ¿Con qué frecuencia te sientes cercano a la gente?
11. ¿Con qué frecuencia te sientes excluido?
12. ¿Con qué frecuencia sientes que tus relaciones con los demás no son significativas?
13. ¿Con qué frecuencia sientes que nadie te conoce realmente bien?
14. ¿Con qué frecuencia te sientes aislado de los demás?
R15. ¿Con qué frecuencia sientes que puedes encontrar compañía cuando la deseas?
R16. ¿Con qué frecuencia sientes que hay personas que realmente te entienden?
17. ¿Con qué frecuencia te sientes tímido?
18. ¿Con qué frecuencia sientes que hay gente a tu alrededor pero no contigo?
R19. ¿Con qué frecuencia sientes que hay personas con las que puedes hablar?
R20. ¿Con qué frecuencia sientes que hay personas a las que puedes recurrir?

Soledad en estudiantes universitarios: análisis estadístico Como primer paso, analizamos la distribución de la soledad entre nuestros participantes. Como se mencionó, categorizamos las puntuaciones de soledad de UCLA en niveles de soledad bajos ( $\leq 40$ ) y altos ( $> 40$ ). Luego calculamos la distribución de las puntuaciones generales, así como la distribución de las respuestas a cada pregunta en la escala de soledad de UCLA. Este análisis ayuda a identificar el nivel de respuesta común a cada pregunta. Además, calculamos las diferencias entre las puntuaciones de soledad antes y después del semestre para comprender el cambio en la soledad a lo largo del semestre. Repetimos este análisis con cada pregunta y medimos la cantidad de cambio en las respuestas de los estudiantes. Mostramos la distribución de las preguntas calificadas igual, por encima o por debajo de la soledad previa al semestre en las mediciones posteriores, identificando así los elementos que tenían más probabilidades de cambiar que otros con el tiempo.

Patrones de comportamiento de la soledad: análisis de minería de datos

Además de capturar las relaciones entre cada característica de comportamiento y la soledad, también estábamos interesados en extraer patrones de comportamiento combinados asociados con la soledad. Medimos la proporción de nuestra población de estudio que estaba cubierta por estas combinaciones de patrones de comportamiento y discutimos las implicaciones tecnológicas de estas observaciones. También exploramos asociaciones entre las respuestas a preguntas individuales y el nivel de soledad, así como las características de comportamiento y el nivel de soledad.

Aplicamos Apriori [19], un conocido algoritmo de conjuntos de elementos frecuentes para descubrir asociaciones entre elementos en

conjuntos de datos transaccionales, para extraer patrones entre el nivel general de soledad y preguntas combinadas, así como patrones de comportamiento combinados que estaban más asociados con el nivel de soledad. Apriori extrae patrones en 2 pasos: primero genera un conjunto de elementos frecuentes que aparecen juntos y luego extrae reglas de asociación que explican la relación entre esos elementos frecuentes. Las reglas extraídas deben satisfacer un cierto grado de apoyo y confianza en el conjunto de datos. Por ejemplo, sean A y B dos conjuntos de elementos. Existe una asociación ( $A \rightarrow B$ ) si los elementos de A y B aparecen juntos con frecuencia en las transacciones. El soporte es el porcentaje de transacciones que contienen A y B, mientras que la confianza es el porcentaje de transacciones que contienen A y también contienen B [20], es decir, soporte ( $A \rightarrow B$ )= $P(A \cup B)$  y confianza ( $A \rightarrow B$ )= $P(B|A)$ . Tenga en cuenta que la notación  $P(A \cup B)$  indica la probabilidad de que una transacción contenga los conjuntos de unión de A y B (es decir, contenga todos los elementos de A y B). Esto no debe confundirse con  $P(A \text{ o } B)$ , que indica la probabilidad de que una transacción contenga A o B [20].

Para simplificar el proceso de minería de patrones, discretizamos aún más las características de comportamiento en categorías de baja, moderada y alta utilizando agrupaciones con igual frecuencia. Luego aplicamos Apriori en el conjunto de funciones seleccionado generado en el proceso de aprendizaje automático que se describe en la siguiente sección.

Detección del nivel de soledad y cambio en Soledad: análisis del aprendizaje automático

Para explorar el uso de la detección pasiva para inferir el estado de soledad, definimos la detección de soledad como un problema de clasificación binaria, donde los datos de comportamiento agregados

a lo largo del semestre se utilizaron como vectores de características para inferir el nivel de soledad (bajo o alto). Seguimos la misma categorización descrita anteriormente para etiquetar las puntuaciones de soledad como bajas o altas. Nuestro proceso de modelado (Figura 1) maneja cada sensor por separado (llamado conjunto de 1 característica) durante el entrenamiento y la validación y proporciona un resultado de clasificación final combinado al final. El uso de conjuntos de 1 característica brinda la posibilidad de examinar el poder predictivo de cada sensor solo y combinado.

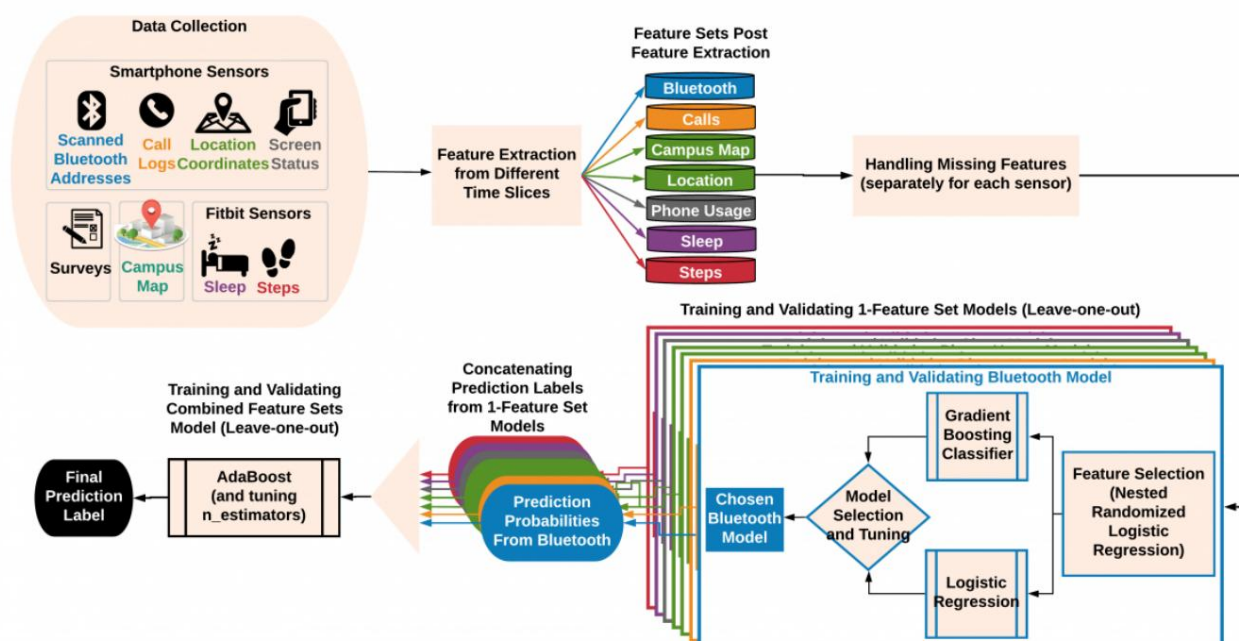
Específicamente, nuestro enfoque comprendió los siguientes procesos:

1. Procesamiento pasivo de datos y extracción de funciones
2. Manejo de valores faltantes
- 3.

Entrenamiento y validación de modelos que usan solo 1 conjunto de funciones para cada uno de los siguientes 7 conjuntos de funciones: Bluetooth, llamadas, mapa del campus, ubicación, uso del teléfono, suspensión y Pasos 4. Obtener la etiqueta final para el resultado combinando probabilidades de detección de modelos de conjunto de 1 característica.

Los procesos se describen en las siguientes secciones.

Figura 1. Canal de aprendizaje automático que incluye recopilación de datos, extracción de características, capacitación y validación, y resultado final.

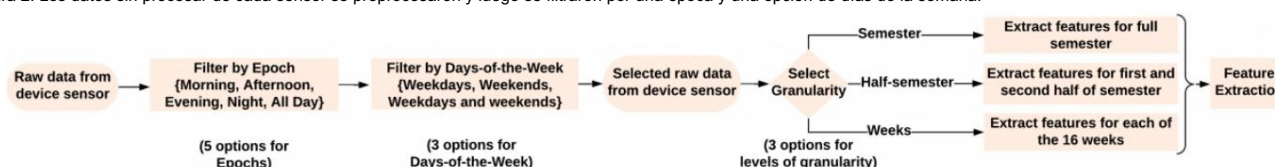


Procesamiento pasivo de datos y extracción de funciones Nuestros datos incluían datos de series temporales de Bluetooth, llamadas, SMS, Wi-Fi, ubicación, uso del teléfono, pasos y sueño. Estos canales de detección tienen el potencial de capturar patrones de comportamiento diarios relacionados con la soledad, es decir, patrones de movilidad y actividad, comunicación e interacción social y sueño. Desarrollamos un componente de extracción de características (FEC) genérico y flexible [21] para extraer características de los datos sin procesar de los sensores recopilados de los teléfonos inteligentes y dispositivos Fitbit. FEC calcula características a partir de flujos de datos con marca de tiempo en segmentos de tiempo específicos que van desde 5 minutos hasta varios meses. De los flujos de datos, FEC extrae un conjunto de características estadísticas comunes, como mínimo, mediana, media, máxima y desviación estándar, así como características de comportamiento más complejas, como la regularidad del movimiento y la distancia recorrida. Cada característica de cada serie de datos de tiempo se extrajo de 45 segmentos de tiempo ilustrados en la Figura 2. Primero, obtuvimos todos los datos disponibles (que abarcan múltiples

días del estudio) de una determinada época o hora del día (todo el día; noche, es decir, 12 am-6 am; mañana, es decir, 6 am-12 pm; tarde, es decir, 12 pm-6 pm; y noche, es decir, de 6 p. m. a 12 a. m.) y para ciertos días de la semana (todos los días de la semana; solo entre semana, es decir, de lunes a viernes; solo los fines de semana, es decir, de sábado a domingo). Luego, calculamos características a partir de estos datos agregados en diferentes niveles de granularidad (por ejemplo, todo el semestre, dos mitades del semestre y semanalmente). Como hay 5 épocas, 3 segmentaciones de días de la semana y 3 niveles de granularidad, obtenemos  $5 \times 3 \times 3 = 45$  segmentos de tiempo. Tenga en cuenta que las 2 mitades del semestre no son mitades perfectas. Para simplificar, nos referimos a la semana 1 a la semana 6 (antes de los exámenes parciales) como la primera mitad y a la semana 7 a la semana 16 (a los exámenes parciales y después de los exámenes parciales) como la segunda mitad. En total, extrajimos 77.805 características de nuestros datos de series temporales en combinación con diferentes segmentos temporales. El código fuente para extraer estas funciones estará disponible previa solicitud.

A continuación se describen las características extraídas en cada categoría de comportamiento

Figura 2. Los datos sin procesar de cada sensor se preprocesaron y luego se filtraron por una época y una opción de días de la semana.





### Características de movilidad y actividad física Las

características relacionadas con la movilidad se extrajeron de las coordenadas GPS, incluida la variación de ubicación (suma de la variación en las coordenadas de latitud y longitud), el registro de la variación de ubicación, la distancia total recorrida, la velocidad promedio y la variación de la velocidad.

Seguimos el enfoque del estudio de Tan et al [22], que utilizó el método Lomb-Scargle [23] para extraer la regularidad del movimiento a partir de patrones de ubicación que siguen un ciclo de 24 horas.

Se extrajeron características adicionales mediante el siguiente proceso:

1. Calculamos la velocidad de movimiento a partir de la distancia recorrida y el tiempo transcurrido entre 2 muestras. Las muestras con una velocidad >1 km/h se etiquetaron como en movimiento, en caso contrario, estáticas.
2. Las muestras etiquetadas como estáticas se agruparon mediante agrupación espacial de aplicaciones con ruido basada en la densidad (DBSCAN), un algoritmo de agrupación basado en la densidad [24] para encontrar lugares visitados frecuentemente por el participante y etiquetados como grupos globales o locales. DBSCAN agrupa eficientemente puntos espaciales cercanos y distingue puntos atípicos. A diferencia de otros algoritmos de agrupación, como k-means, DBSCAN no requiere conocer el número de agrupaciones a priori. Es capaz de encontrar clusters internos (clusters rodeados por otros clusters) y es resistente a los valores atípicos y al ruido. Los grupos globales se extrajeron utilizando todos los datos y los grupos locales se extrajeron cuando los datos se dividieron en segmentos de tiempo diarios descritos anteriormente.

Estos pasos nos permitieron extraer la cantidad de lugares frecuentes, la cantidad de transiciones entre lugares, el radio de giro [25], el tiempo pasado en los 3 principales grupos locales y globales (los más frecuentes), el porcentaje de tiempo dedicado a moverse y el porcentaje de tiempo dedicado. en lugares poco frecuentes o raramente visitados (etiquetados como -1 por DBSCAN). También calculamos estadísticas relacionadas con la duración de la estadía en los conglomerados, como la desviación máxima, mínima, promedio y estándar de la duración de la estadía en los conglomerados locales y globales, así como la entropía de ubicación y la entropía de ubicación normalizada en los conglomerados locales y globales. La entropía de la ubicación es mayor cuando el tiempo se emplea de manera uniforme en lugares frecuentes.

El cálculo de funciones para clústeres locales y globales nos permitió capturar diferentes comportamientos relacionados con los patrones de ubicación generales del usuario (global) y los patrones de ubicación del usuario dentro de un intervalo de tiempo (local). Por ejemplo, el tiempo invertido en los 3 principales grupos globales y locales captura el tiempo invertido en los lugares frecuentes generales del usuario y en la ubicación frecuente del usuario en un intervalo de tiempo particular (por ejemplo, por las mañanas los fines de semana). Asumimos que el lugar más visitado por el participante durante la noche era su domicilio.

Para aproximar la ubicación del hogar, realizamos los pasos (1) y (2) mencionados anteriormente en las coordenadas de ubicación de todas las noches (de 12 am a 6 am) y asumimos que el centro del grupo más frecuentado es el centro de ubicación del hogar del participante. Como no conocemos el radio de la casa, calculamos dos características relacionadas con la casa: el tiempo pasado en casa suponiendo que la casa está dentro de los 10 metros del centro de ubicación de la casa y el tiempo pasado en casa suponiendo que la casa está dentro de los 100 metros de la casa. centro de ubicación. También analizamos los patrones de ubicación del usuario en relación con su campus universitario. Primero, obtuvimos un mapa del campus de la universidad de los participantes. Luego, marcamos los límites del campus y los diferentes tipos de edificios en

campus mediante la creación de polígonos en Google Maps utilizando un sistema de información geográfica en línea. Anotamos 6 categorías de edificios y espacios: 2 casas diferentes que albergan la mayoría de eventos sociales, apartamentos para estudiantes, residencias, instalaciones deportivas y espacios verdes. Como los edificios académicos de esta universidad a menudo están ubicados con otros espacios, asumimos que cualquier espacio en el campus que no pertenezca a estas 6 categorías es un edificio académico. Para cada muestra de ubicación, asignamos 1 de 8 etiquetas de categoría de ubicación (6 tipos de edificio/espacio, académico, fuera del campus). Luego, se extrajeron las siguientes características para cada tipo de espacio: tiempo de permanencia en cada tipo de ubicación en min; porcentaje de tiempo pasado en cada tipo de ubicación; número de transiciones entre diferentes espacios; número de combates (o períodos de tiempo continuos) en el espacio; número de combates durante los cuales un participante pasa 10, 20 o 30 minutos en el mismo espacio; y desviación mínima, máxima, media y estándar de la duración de los combates en cada espacio. Las características del mapa del campus también incluyeron dos características multimodales: duración del estudio y duración social. Estas funciones fusionaron datos de sensores de ubicación, uso del teléfono, audio y pasos.

La duración del estudio se calculó fusionando etiquetas de tipo de ubicación con datos del uso del teléfono y sensores de pasos. Se suponía que un participante estaba estudiando si pasaba 30 minutos o más en un edificio académico mientras era sedentario (menos de 10 pasos) y no interactuaba con su teléfono. La duración social se calculó fusionando etiquetas de tipo de ubicación con datos del sensor de audio. Se suponía que un participante era sociable si pasaba 20 minutos o más en cualquiera de los edificios residenciales o espacios verdes y el sensor de audio infería voz humana o ruido durante el 80% o más de ese tiempo. Otras características relacionadas con la actividad y la movilidad se extrajeron de los recuentos de pasos recopilados por Fitbit.

Calculamos el número total de pasos y el número máximo de pasos realizados en cualquier período de 5 minutos. Otras características se extrajeron de los combates, donde un combate es un período de tiempo continuo durante el cual se exhibe una determinada característica. Ejemplos de tales características incluyeron el número total de combates activos o sedentarios [26], y la duración máxima, mínima y promedio de los combates activos o sedentarios. También calculamos el número mínimo, máximo y promedio de pasos en todos los combates activos.

Utilizando directamente los resultados del estudio de Cacioppo et al [26], determinamos que una pelea es sedentaria si el usuario da menos de 10 pasos durante cada intervalo de 5 minutos dentro de la pelea. Tan pronto como el usuario da más de 10 pasos en cualquier intervalo de 5 minutos, cambia a una pelea activa.

## Funciones de comunicación e interacción

Usamos registros de llamadas y SMS para extraer características que incluyen el número y la duración de las llamadas entrantes, salientes y perdidas y los mensajes a todos, a familiares, a amigos fuera del campus y a amigos en el campus, el número de correspondientes en general y el número de correspondientes que sean familiares, amigos fuera del campus o amigos en el campus. También extrajimos características de uso del teléfono relacionadas tanto con la comunicación como con la interacción basada en la Web. Usamos los registros del estado de la pantalla (p. ej., encendido, apagado, bloqueo y desbloqueo) a lo largo del tiempo. Extrajimos la cantidad de desbloques por minuto, el tiempo total dedicado a interactuar con el teléfono, el tiempo total que la pantalla estuvo desbloqueada, la hora de los días en que la pantalla se desbloqueó o encendió por primera vez, la hora de los días en que la pantalla se desbloqueó por última vez, bloqueo y encendido, y el

desviación máxima, mínima, media y estándar de la duración de los combates (o períodos de tiempo continuos) durante los cuales el participante interactuaba con el teléfono y cuando la pantalla estaba desbloqueada. Se dice que un participante interactúa con su teléfono entre el momento en que el estado de la pantalla está desbloqueado y cuando el estado de la pantalla está apagado o bloqueado.

Como las conexiones Bluetooth pueden ser un indicador de la interacción social, también extrajimos características de Bluetooth clasificando primero los dispositivos Bluetooth escaneados en 3 grupos: propios (los propios dispositivos del participante), relacionados (dispositivos que pertenecen a la pareja del participante, compañeros de cuarto o compañeros de clase), y otros (dispositivos no relacionados). Para clasificar las direcciones Bluetooth escaneadas en 3 grupos: propias, relacionadas y otras, hicimos lo siguiente:

1. Calculamos la cantidad de días que se escaneó cada dirección Bluetooth única al menos una vez, es decir, número\_de\_díasbt.
2. Calculamos la frecuencia promedio de cada dirección Bluetooth única, es decir, frecuencia\_promediobti = total\_countbti / número\_de\_díasbt.
3. Normalizamos en Z el número\_de\_díasbt y la frecuencia\_promediobti para darles el mismo peso a ambos mientras optimizamos la puntuación en el paso 4.
4. Para cada dirección Bluetooth, calculamos la puntuación = número\_de\_díasbt + frecuencia\_promediobti.
5. Usamos agrupación de K-medias para agrupar la puntuación del paso 4 para todas las direcciones Bluetooth usando K=2 y K=3.
6. Se eligió el modelo con K=2 si la suma de las distancias al cuadrado entre los puntos agrupados y los centros de los grupos era menor que lo que obtuvimos con K=3. De lo contrario, elegimos el modelo con K=3.
7. Si se eligió el modelo con K=2, el grupo con puntuaciones más altas contenía los dispositivos propios del participante (yo), mientras que el otro grupo contenía los dispositivos de otras personas (otros). Si se eligió el modelo con K=3, el grupo con las puntuaciones más altas contenía los propios dispositivos del participante (yo), el grupo con las puntuaciones más bajas contenía otros

dispositivos de personas (otros), y el grupo restante contenía dispositivos de los socios, compañeros de habitación o de oficina del participante (relacionados). Una vez que las direcciones de Bluetooth escaneadas se agruparon en propias y otras o propias, relacionadas y otras, extrajimos características que incluyen la cantidad de dispositivos únicos, la cantidad de escaneos del dispositivo más y menos frecuente, y la suma, el promedio y la desviación estándar de el número de escaneos de todos los dispositivos. Cada ronda incluyó todos los dispositivos (ignora los grupos), el grupo propio y relacionado (combinado) y otros grupos.

Funciones del sueño

Las funciones del sueño se extrajeron de las inferencias del sueño (p. ej., dormido, inquieto, despierto y desconocido) a lo largo del tiempo devueltas por la API de Fitbit. Calculamos el número de muestras dormidas, el número de muestras inquietas, el número de muestras despiertas, la eficiencia del sueño débil (la suma del número de muestras dormidas e inquietas dividida por la suma del número de muestras dormidas, inquietas y despiertas), fuerte eficiencia del sueño (la suma del número de muestras dormidas dividida por la suma del número de muestras dormidas, inquietas y despiertas), recuento, suma, duración promedio, máxima y mínima de los combates durante los cuales el participante estuvo dormido, inquieto, o despierto, y la hora de inicio y finalización de los combates más largos y más cortos durante los cuales el participante estuvo dormido, inquieto o despierto.

Matriz de características

Después de la extracción de características, obtuvimos una matriz de características para cada uno de los 7 conjuntos de características derivados de diferentes sensores. En cada una de estas matrices de características, cada muestra o registro contenía características extraídas de un estudiante. Agregamos nuestras funciones en diferentes segmentos de tiempo (descritos en la Figura 2): en diferentes semanas, en las dos mitades del semestre y durante todo el semestre. Las características de todos estos segmentos de tiempo se concatenaron para formar el vector de características de cada estudiante. En la Figura 3 se muestra un esquema de la matriz de características. El esquema de codificación se describe en el [Apéndice Multimedia 1](#) y se presenta una muestra de características seleccionadas.

Figura 3. El esquema de la matriz de características utilizada en el proceso de aprendizaje automático (cada columna es una característica y cada fila es una muestra por participante).

device_id	f_steps_avg_length_activ e_bout_minutes_mo_wkld y_half_sem_2017-01-18	f_steps_avg_length_activ e_bout_minutes_mo_wkld y_half_sem_2017-03-01	f_call_duration_incomin g_calls_seconds_af_wkld y_half_sem_2017-01-18	f_call_duration_incomin g_calls_seconds_af_wkld y_half_sem_2017-01-19	f_blue_number_unique_de vices_of_seif_wkldy_sem_20 17-01-18	f_screen_last_on_Hou r_5_af_wkldy_sem_20 17-01-18	f_loc_home_stay_time_per cent_10m_ev_wkend_sem_20 17-01-18	f_locMap_study_duration_ minutes_af_sem_2017-01- 18	f_steps_max_length_s edentary_bout_minute s_ni_sem_2017-01-18
1	20	13	69	172	3	62	0.0458971	200	610
2	17	21	226	21	1	48	0.100391	230	650
3	13	13	154	0	5	63	0.0789779	90	820
4	15	18	0	495	17	63	0.207094	200	1030
5	18	18	1964	109	2	54	0.075188	1160	1400
...	...	...	...	...	...	...	...	...	...

Manejo de valores faltantes Manejamos

los datos faltantes en base a un conjunto de características: para cada sensor, eliminamos una característica del conjunto de datos si su valor faltaba para más de 30 participantes, y eliminamos a un participante del conjunto de datos si el 20 % de sus faltaban datos. Los umbrales para eliminar datos se determinaron empíricamente. Luego imputamos los valores de características faltantes restantes con un -1. Se eligió esto porque todos los valores de las características estaban por encima de 0 y, como tal, -1 podía distinguir los valores faltantes. Las mismas funciones calculadas en diferentes segmentos de tiempo se vieron de forma independiente; por ejemplo, si faltaba una función durante una semana para más de 30 personas, la eliminamos solo de esa semana. Como tal, el número de muestras que se utilizaron en el entrenamiento

y la validación para cada conjunto de características varió. Por ejemplo, cuando se entrenaba con funciones semestrales, el conjunto de funciones más pequeño pertenecía a la ubicación (con 118 muestras) y los conjuntos más grandes eran Bluetooth y uso del teléfono (con 134 muestras).

Creación y validación de modelos de conjunto de 1 característica

La creación y validación de modelos de conjunto de 1 característica siguió 3 pasos:

1. Selección de funciones
2. Entrenamiento de 2 algoritmos, a saber, regresión logística y aumento de gradiente, para construir modelos de cada conjunto de funciones utilizando funciones seleccionadas
3. Seleccionar el modelo con mayor precisión

Todos estos pasos se realizaron en un sistema de dejar a un estudiante fuera. validación cruzada, es decir, en cada paso del entrenamiento y función selección, construimos un modelo separado utilizando datos de n–1 estudiantes y lo probé en el enésimo estudiante. Tenga en cuenta que los datos de cada Los estudiantes fueron representados como una muestra en cada conjunto de características en la forma de un vector.

Selección de características

La amplia gama de características de comportamiento proporciona la posibilidad. extraer información sobre diferentes tipos y granularidad de comportamiento en relación con la soledad. Sin embargo, la gran cantidad de características dificulta que el algoritmo de clasificación construir un modelo integral de datos, especialmente cuando el tamaño del conjunto de muestra (por ejemplo, número de participantes) es proporcionalmente más pequeño que el conjunto de características. Por lo tanto, aplicamos la característica selección para reducir el número de características a un conjunto que es representativo de nuestros datos. Experimentamos con diferentes métodos de selección de características que incluyen la contracción mínima absoluta y operador de selección (LASSO) [27] y logística aleatoria regresión [28] que han demostrado funcionar bien en seleccionar un conjunto estable de características. En nuestro caso, porque el número de características en cada conjunto de características era sustancialmente mayor que el tamaño de la muestra, esos métodos funcionaron mal y la precisión de modelos era bajo. Por lo tanto, aplicamos logística aleatoria. regresión de forma jerárquica y anidada en grupos de

características en cada segmento de tiempo. Regresión logística aleatoria crea varias submuestras aleatorias del conjunto de datos de entrenamiento, calcula una regresión logística en cada submuestra y selecciona características optimizando su importancia en todas las submuestras. Descompusimos nuestro espacio de características agrupando características de el mismo segmento de tiempo y realizó logística aleatoria regresión en cada uno de estos grupos. Las características seleccionadas de Todos los grupos (es decir, todos los segmentos de tiempo) se concatenaron para dar un conjunto de características nuevo y mucho más pequeño. Luego, aleatorizado La regresión logística se realizó nuevamente, esta vez en este nuevo conjunto de características para obtener las características finales seleccionadas, anidando así el proceso. A este método lo llamamos logística aleatoria anidada. regresión (NRLR). Este método se realizó en un manera de dejar uno fuera de modo que el modelo utilizado para detectar un El resultado para una persona no incluyó los datos de esa persona. durante el proceso de selección de funciones.

La Tabla 1 (columnas 1 a 3) muestra el número de características y el número de muestras para cada conjunto de características después de manejar los valores faltantes donde todas las características se utilizaron como entrada para la capacitación y validación. La Tabla 1 (columnas 4-7) muestra una comparación entre las características seleccionadas con LASSO y NRLR. Comparado con LASSO, el número promedio de características estables seleccionadas (características seleccionado en todos los pliegues de validación cruzada) es 3 veces menor en NRLR eso reduce sustancialmente el tamaño del vector de características.

Tabla 1. La lista de conjuntos de características con la cantidad de características y muestras de datos utilizados en el proceso de aprendizaje automático después de manejar los valores faltantes y el número de características seleccionadas durante el proceso de validación cruzada.

Conjunto de características	Número de características	Número de muestras	Número de funciones seleccionadas durante el proceso de validación cruzada			
			el lazo		NLRb	
			en todos los pliegues	Al menos en un pliegue	en todos los pliegues	Al menos en un pliegue
Bluetooth	3201	115	203	1026	278	1864
llamadas	605	108	30	134	34	142
Mapa del campus	16.381	111	66	455	12	161
Ubicación	10.237	106	345	784	14	124
Pantalla	15.446	113	96	467	8	52
Dormir	5889	107	87	534	23	266
Pasos	3055	107	270	485	0	8
Promedio	7831	110	157	555	53	374

aLASSO: operador de selección y contracción mínima absoluta.  
bNRLR: regresión logística aleatoria anidada.

Generación de modelos

Para cada conjunto de características, creamos un modelo de las características seleccionadas. de ese conjunto de características para detectar un resultado usando 2 aprendizaje algoritmos, a saber, regresión logística y aumento de gradiente clasificador. Elegimos la regresión logística porque se utilizó en nuestro enfoque de selección de características, y se eligió el aumento de gradiente porque había demostrado funcionar bien en conjuntos de datos ruidosos y aprenda límites de decisión no lineales complejos mediante el impulso. El aumento de gradiente se había utilizado eficazmente para detectar resultados en un estudio anterior [29].

Selección de modelo

Los modelos generados a partir de regresión logística y gradiente. Luego se evaluaron los refuerzos comparando su precisión como Métrica para post-semestre y cambio en la soledad. El modelo El que proporcionaba mayor precisión fue seleccionado para el siguiente paso.

Combinando probabilidades de detección de 1 característica  
Establecer modelos para obtener modelos combinados

El modelo de conjunto de 1 característica elegido en el paso anterior nos dio probabilidades de detección para cada etiqueta de resultado. la detección Se concatenaron las probabilidades de los 7 modelos de conjuntos de 1 característica. en un único vector de características y dado como entrada a un conjunto clasificador, AdaBoost con aumento de gradiente como base



estimador, que luego generó la etiqueta final para el resultado.

Para la detección de la soledad post-semestral, que es una clasificación binaria, solo se concatenaron las probabilidades inferidas de una de las clases (baja o alta), mientras que para la detección de cambios en la soledad (clasificación multiclase: soledad disminuida, soledad aumentada y soledad sin cambios). soledad), se concatenaron las probabilidades inferidas de todas las clases.

También llevamos a cabo un estudio de ablación de características para analizar el efecto que tenían diferentes conjuntos de características en el rendimiento de los modelos, comprendiendo así su prominencia. Para este propósito, concatenamos probabilidades de detección de modelos de conjuntos de 1 característica específicos en lugar de los 7 modelos de conjuntos de 1 característica. Hicimos esto para todas las combinaciones posibles de modelos de conjunto de 1 característica para analizar el poder de estimación de cada conjunto de características al inferir el nivel de soledad. Hubo 7 modelos de conjuntos de 1 característica y 120 combinaciones de conjuntos de características, como combinaciones totales = combinaciones con 2 características conjuntos + ... + combinaciones con 7 conjuntos de características = 120. Informamos las mejores precisiones obtenidas de estas combinaciones.

## Medidas

Resumimos nuestras medidas utilizadas a lo largo del artículo de la siguiente manera:

- Puntuación previa a la soledad: puntuación total de soledad de UCLA medida al comienzo del semestre
- Puntuación possoledad: puntuación total de soledad de UCLA medida al final del semestre. • Puntuación aumentada: cuando la puntuación possoledad era mayor que la puntuación previa a la soledad. • Puntuación disminuida: cuando la puntuación possoledad era menor. puntuación previa a la soledad
- Puntuación sin cambios: cuando la puntuación posterior a la soledad era igual a la puntuación previa a la soledad

Nivel de soledad (antes o después del semestre): 2 categorías:

- Soledad baja (LL): puntuaciones totales de UCLA de 40 o menos. • Soledad alta (HL): puntuaciones totales de UCLA superiores a 40.
- Cambio en el nivel de soledad de antes a después: 3 categorías: • Disminución de la soledad (DL): el nivel de soledad cambió de alto en el presemestre a bajo en el possemestre • Aumento de la soledad (IL): el nivel de soledad cambió de bajo en el presemestre a alto en el possemestre

- Soledad sin cambios (UL): el nivel de soledad permaneció igual antes y después del semestre

Medidas de aprendizaje automático:

- Precisión de referencia: porcentaje de muestras que pertenecen a la clase mayoritaria (aquí HL). Este porcentaje se compara con el resultado de la clasificación para medir el rendimiento de los algoritmos de aprendizaje automático. • Precisión: porcentaje de muestras clasificadas correctamente (1 por estudiante). • Precisión: porcentaje de muestras clasificadas que realmente pertenecían a una clase, por ejemplo, HL o LL. • Recuerdo: porcentaje de muestras de clase que se clasificaron con precisión.

clasificado

- F1: media armónica de precisión y recuperación. • MCC: una medida de calidad de la clasificación binaria. El valor está entre -1 y 1, donde 1 indica una predicción perfecta, 0 indica que no es mejor que la predicción aleatoria y -1 indica un desacuerdo total entre la predicción y la observación.

## Resultados

Soledad en estudiantes universitarios Analizamos

los puntajes totales de soledad de UCLA para las encuestas presemestrales y posteriores al semestre. La puntuación promedio de las encuestas presemestrales estuvo por encima del punto de corte (media 43,6, mediana 44, Q1=37, Q3=49 y DE 9,4) y el 63,8 % (102/160) de los participantes se ubicaron en la categoría HL (puntuaciones superiores a 40). ).

De manera similar, al finalizar el semestre, la puntuación promedio de soledad estuvo por encima del límite (media 43,3, mediana 43, Q1=37, Q3=50 y DE 10,4) y el 58,8 % (94/160) de los participantes cayeron en la categoría HL. La Figura 4 muestra la distribución de las puntuaciones de UCLA antes y después del semestre.

Una prueba pareada no mostró diferencias significativas entre las dos distribuciones ( $p = 0,73$ ). Observamos que la puntuación de soledad para el 12,5% (20/160) de los participantes estaba 1 desviación estándar por encima de la media tanto antes como después del semestre. Sin embargo, la mayoría de las puntuaciones se situaron en el rango entre 1 desviación estándar por debajo y por encima de la media (pre=66,9% [107/160] y post=73,1% [117/160]). La Tabla 2 muestra el resumen de las estadísticas.

Figura 4. Distribución de las puntuaciones presemestrales de la Universidad de California, Los Ángeles (media 43,6, DE 9,4) y de las puntuaciones postsemestrales de la Universidad de California, Los Ángeles (media 43,3, DE 10,4). UCLA: Universidad de California, Los Ángeles.




Tabla 2. Estadísticas de puntuaciones altas y bajas de soledad medidas por la escala de la Universidad de California, Los Ángeles, antes y después de las encuestas.

Categoría	Contar		Promedio		mín.		máx.	
	Pre	Correo	Pre	Correo	Pre	Correo	Pre	Correo
Todo	160	160	43,6	43.3	-a -		-	
LL <sup>b</sup>	58 (36,2%)	66 (41,2%)	33,9	33,7	24	20	40	40
HL <sup>c</sup>	102 (63,8%)	94 (58,8%)	49.1	49,9	41	41	72	72

aDato no aplicable.  
bLL: soledad baja.  
cHL: alta soledad.

El porcentaje de participantes con una puntuación alta después de la soledad. fue un 5% más bajo que aquellos con puntuaciones altas previas a la soledad (58,75% vs 63,75%), lo que indica una tasa general de soledad más baja entre estudiantes al final del semestre. Sólo 6 participantes que tenían puntuaciones bajas de soledad en la encuesta presemestral mostraron una alta nivel de soledad en la encuesta posterior al semestre, mientras que 7 los participantes obtuvieron una puntuación HL en la encuesta presemestral pero una Puntaje LL en la encuesta post-semestre. El aumento promedio y La disminución fue de 6 y 7 puntos, respectivamente. En total, 17,5% (28/160) de los participantes informaron un aumento de más de 6 puntos en sus puntuaciones de possoledad, el 18,8% (30/160) informó una sensación más disminución de más de 7 puntos, el 58,2% (93/160) permaneció en el rango de menor aumento (entre 1 y 6) o menor disminución (entre 1 y 7), y el 5,6% (9/160) no experimentó cambios. El El aumento máximo en las puntuaciones fue de 17 puntos (frente a 35 en encuesta presemestral a 52 en el post) y la máxima disminución en puntuaciones fue de 30 puntos (en comparación con 58 en el semestre anterior) encuesta a 28 en el puesto). Estas observaciones indicaron que aunque Hubo cambios en las puntuaciones de soledad entre la mayoría de los participantes (154/160), estos cambios fueron en su mayoría moderados y rara vez hizo que los participantes cayeran en una categoría diferente de soledad entre las encuestas previas y posteriores al semestre. Debido a los niveles relativamente estables de soledad, predecir El cambio en los niveles de soledad fue más desafiante. Sin embargo, como descrito en las siguientes secciones, utilizando características de comportamiento


En nuestro proceso de aprendizaje automático, aún pudimos inferir cambio en la soledad con una precisión superior al 88%.

También examinamos el cambio en las puntuaciones de cada individuo. pregunta (Tabla 3). Dado nuestro objetivo final de medir la Poder de las características de detección pasiva para distinguir la soledad. comportamiento, teníamos curiosidad por saber lo siguiente: (1) por cómo Cuánto cambia la puntuación de cada pregunta de presemestre a después del semestre, (2) qué preguntas tuvieron el mayor cambio en la puntuación, y (3) si hubo asociaciones entre esos cambios y las características de comportamiento. La figura 5 muestra el porcentaje de participantes calificaron cada pregunta como 3 o más (a veces o siempre). Por ejemplo, la calificación total del segundo trimestre (¿Con qué frecuencia ¿Sientes que te falta compañía?) disminuyó en un 14% desde presemestre a postsemestre lo que indica que menos estudiantes sintieron una falta de compañerismo al final del semestre que al final. comienzo. Los mayores cambios se observaron en el cuarto trimestre (¿Con qué frecuencia? ¿te sientes solo?) y QR19 (¿Con qué frecuencia sientes que hay ¿Hay personas con las que puedes hablar?) con una disminución total del 16% y un aumento del 14%, respectivamente. Aunque se realizan más análisis necesario para replicar estas observaciones, pueden ser indicativas de cambios en experiencias específicas entre los estudiantes. Por ejemplo, una disminución en las puntuaciones de falta de compañerismo (Q2) puede indican que los participantes se familiarizaron más con el ambiente universitario y eran más capaces de hacer amigos el final del semestre.

Tabla 3. Estadísticas de cambio en las puntuaciones de soledad medidas por la escala de la Universidad de California, Los Ángeles, en las encuestas previas y posteriores (N=160).

Cambio en la puntuación de soledad	Participantes, n (%)
Puntuación aumentada	
En general	75 (47)
Incrementar entre 1 y 6 puntos	47 (29)
Aumentar más de 6 puntos.	28 (17)
Puntuación disminuida	
En general	76 (47)
Disminución entre 1 y 7 puntos	46 (29)
Disminución de más de 7 puntos.	30 (19)
Puntuación sin cambios	9 (6)

Figura 5. Comparación de las calificaciones de soledad anteriores y posteriores a las preguntas de la Universidad de California, Los Ángeles (Q2, Q4 y Q19 tienen el mayor cambio en calificaciones posteriores a la soledad). P: pregunta; UCLA: Universidad de California, Los Ángeles.



Asociaciones mineras entre la soledad general y Universidad de California, Los Ángeles, puntuaciones de preguntas

Aplicamos el algoritmo Apriori (descrito en Métodos sección) a las respuestas de la encuesta previa y posterior al semestre para extraer asociaciones entre las respuestas a cada pregunta y nivel general de soledad. Nuestro objetivo fue identificar experiencias expresado como respuestas a cada pregunta, que en su mayoría fueron asociado con la soledad en estudiantes universitarios, y luego examinar si alguna asociación entre esas experiencias y pasiva Se pueden observar características de comportamiento. Empezamos con un soporte mínimo del 10% y lo incrementó en cada iteración para obtener un conjunto mínimo de reglas de asociación con un máximo apoyo. El apoyo mínimo óptimo se alcanzó en un 38%, es decir, los patrones extraídos se observaron en al menos el 38% de los

los estudiantes. Dejamos de aumentar el soporte mínimo después 38% ya que no se pudieron encontrar reglas para un soporte superior a ese porcentaje. Mantuvimos la confianza mínima en 90%. Como se muestra en la Tabla 4, pregunta 14 (¿Con qué frecuencia se siente aislado de ¿Otros?) aparece en encuestas previas y posteriores al semestre y indica que alrededor del 42% de los estudiantes con respuestas de 3 o 4 a esta pregunta también tuvo una puntuación alta de soledad total. Respuestas de 3 o 4 a la pregunta 13 (¿Con qué frecuencia siente que nadie ¿Realmente te conoce?) parecía indicar una alta soledad total. puntuaciones en la encuesta presemestral con un 49% de apoyo (casi la mitad de la población participante) y 96% de confianza. Lo mismo Se observó asociación con la pregunta 12 (¿Con qué frecuencia ¿Sientes que tus relaciones con los demás no son significativas?) en la encuesta postsemestre con 41% de apoyo y 94% de confianza.

Tabla 4. Reglas de asociación extraídas de las respuestas previas y posteriores a la encuesta.


Nivel de respuesta a la pregunta (a veces o siempre), escala de 1 a 4	Nivel de soledad (bajo o alto)	Soporte, % (mínimo apoyo = 38%)	Confianza, % (mínimo confianza 90%)
Encuesta previa			
Sentir que nadie te conoce realmente bien (UCLAa 13 ≥ 3)	Alto	49	96
Sentirse aislado (UCLA14 ≥ 3)	Alto	41	95
post-encuesta			
Las relaciones no son significativas (UCLA12 ≥ 3)	Alto	41	94
Sentirse aislado (UCLA14 ≥ 3)	Alto	42	94

aUCLA: Universidad de California, Los Ángeles.

Detección del nivel de soledad y cambio en la soledad Ejecutamos nuestro proceso de aprendizaje automático para inferir 2 resultados: nivel posterior a la soledad (bajo o alto) y cambio en el nivel de soledad (IL, DL y UL). Para ambos resultados, utilizamos el conjunto de características de todas las épocas extraídas de todos los intervalos de tiempo y intervalos de tiempo como se describe en la sección de procesamiento, así como características agregadas por semestre (a nivel de semestre). Nuestro objetivo era identificar un conjunto mínimo de características capaces de inferir con precisión el nivel de soledad. Mientras que las características de todas las épocas brindaron la oportunidad de analizar el comportamiento en un nivel más detallado, las características a nivel de semestre proporcionaron un conjunto reducido que describía el comportamiento general de cada participante durante el semestre.

Las Figuras 6 y 7 muestran los resultados de precisión para ambos resultados y su comparación con la línea de base (56,9%: el porcentaje de participantes evaluados en el nivel NS en la encuesta posterior al semestre). Los gráficos muestran la precisión obtenida de las funciones específicas del sensor (un conjunto de funciones), todos los conjuntos de funciones combinados y el conjunto que proporciona la mejor precisión general. Para la detección de soledad, nuestro proceso de aprendizaje automático logró la precisión más alta del 80,2 %, utilizando funciones de todas las épocas en el mejor conjunto de funciones que incluía registros de llamadas, ubicación, mapa de ubicación, pantalla, sueño y pasos. Esta precisión fue un 6,1 % mayor que la precisión obtenida al utilizar los 7 conjuntos de funciones (74,1 %) e indicó que la inclusión de funciones Bluetooth contribuyó a la reducción del rendimiento. Las funciones exclusivas de Bluetooth para todas las épocas proporcionaron una precisión del 55,6%, lo que confirma su bajo poder de predicción.

Figura 6. Detección del nivel de soledad (alta soledad o baja soledad) utilizando funciones de todas las épocas y funciones a nivel de semestre. Cada barra muestra la precisión seguida del número de muestras utilizadas en el análisis entre paréntesis; la barra gris representa la precisión de referencia medida por el porcentaje de muestras que pertenecen a la clase mayoritaria aquí, es decir, alta soledad. Sem: semestre.



en la detección del nivel de soledad. A excepción de Bluetooth, todos los demás conjuntos de funciones y sus combinaciones lograron una precisión mayor (al menos un 5,4%) que la medida de referencia. Las funciones a nivel semestral, incluida la combinación de Bluetooth, ubicación, pantalla y pasos, proporcionaron la mejor precisión establecida del 74,8 %, que fue un 5,5 % más alta que todas las funciones establecidas (69,3 %). El conjunto de funciones de nivel semestral para llamadas tuvo la precisión más baja: 55,2 % (1,7 % menos que el valor inicial). Una posible razón para esto podría ser la gran cantidad de valores de funciones faltantes para las llamadas, lo que significa que se estaban realizando llamadas a una gran cantidad de personas que no estaban en las listas de contactos frecuentes que los participantes proporcionaron antes del semestre de estudio. En general, el análisis con características de todas las épocas incluídas proporcionó mejores resultados que el análisis con características a nivel de semestre para detectar el nivel de soledad (un 5,4% más de precisión). Como punto de comparación, también utilizamos las funciones seleccionadas a través de LASSO en nuestra canalización para comparar el rendimiento (es decir, la precisión). La precisión promedio obtenida de todos los conjuntos de características fue del 56,7 %, lo que está por debajo del valor de referencia del 56,9 %. Esto indica que nuestro enfoque de selección de funciones más sofisticado mejoró el rendimiento.

La Tabla 5 resume los mejores resultados para ambas inferencias distinguiendo el desempeño de los clasificadores para inferir cada clase. Los valores de recuperación (el porcentaje de instancias clasificadas correctamente) indican que el clasificador etiquetó correctamente las instancias de HL el 76,9 % del tiempo usando características de todas las épocas y el 74,6 % del tiempo usando características de nivel semestral.

Figura 7. Detección de cambios en el nivel de soledad (disminución de la soledad, mayor soledad y soledad sin cambios) utilizando funciones de todas las épocas y características a nivel semestral. Cada barra muestra la precisión seguida del número de muestras utilizadas en el análisis entre paréntesis y la precisión inicial. es el porcentaje de muestras que pertenecen aquí a la clase mayoritaria, es decir, la soledad sin cambios. Sem: semestre.




Tabla 5. Rendimiento de los modelos obtenidos a partir de características de todas las épocas y características a nivel de semestre para detectar el nivel de soledad y el cambio en la soledad.

Medida	nivel de soledad						Cambio en la soledad							
	Características de todas las épocas, línea base = 58,5%			Funciones a nivel semestral, línea de base = 58,5%			Características de todas las épocas, línea de base = 69,3%				Características a nivel semestral, línea de base = 69,3%			
	HLa promedio	Promedio LL		Promedio HL	LL		IL DLc		UL Promedio DL		IL		UL	
Precisión, %	80,2	f	74,8	—	79,2	—	—	88,4	—	—	—	—	—	—
Precisión, %	80,3		81.1	79,5	74,6	78,6	70,6	70.2	53.3	71,4	85,7	90.0	90,9	91,6
Recordar, %	80.1		76,9	83.3	74,8	74,6	75.0	67,7	40	71,4	91,6	82,6	75,8	73.3
F1 -, %	80.1		78,9	81.3	74,6	76,5	72,7	68,5	45,7	71,4	88,5	81.0	68,9	81,5
MCCh	0,6	—	0,5	—	0,6	—	0,7	—	—	—	—	—	—	—

aHL: alta soledad.  
bLL: soledad baja.  
cDL: disminución de la soledad.  
dIL: aumento de la soledad.  
eUL: soledad inmutable.  
fFecha no aplicable.  
g F1: media armónica de precisión y recuperación.  
hMCC: una medida de la calidad de la clasificación binaria.

La detección de cambios en los niveles de soledad proporcionó ligeramente resultados diferentes. Utilizando funciones de todas las épocas, el mejor conjunto de funciones incluyendo llamadas y estado de la pantalla logró una precisión del 78,3%, mientras que el mejor conjunto se obtuvo con el nivel semestral funciones, que incluían Bluetooth, llamadas, ubicación y ubicación mapa: logró una precisión del 88,4 %. En contraste con la soledad modelo de detección, donde el análisis con características de todas las épocas proporcionó mejores resultados, en estos modelos para detectar cambios, las características a nivel semestral contribuyeron a una mayor precisión utilizando el mejor conjunto (88,4% con solo semestre versus 78,3% con todas las épocas) características) y los 7 conjuntos (80,2% solo con semestre versus 67,9% con características de todas las épocas).

Para una mayor soledad, estos valores de recuerdo fueron del 71,4% y 73,3%, respectivamente. Aunque se necesitan más análisis para replicar estos resultados, encontramos que a pesar de que todas las épocas Las características proporcionan una precisión ligeramente mayor, estas características solo dio un 2,3% mejor recuerdo para detectar HL. Tampoco encontramos diferencia estadísticamente significativa entre las precisiones obtenido de características de todas las épocas y características de solo el semestre (p=0,58). Sin embargo, las características seleccionadas de todas las épocas durante el El proceso de capacitación y validación proporcionó un conjunto detallado de patrones de comportamiento asociados con el nivel de soledad que se observaron semana a semana como se describe a continuación



(Tablas 6 y 7). Estos patrones no se pudieron extraer utilizando funciones a nivel de semestre.

Las características seleccionadas con mayor frecuencia indican su alto impacto en la detección de la soledad (consulte el [Apéndice multimedia 1](#) para obtener la lista de características seleccionadas solo para el semestre en cada conjunto de características que aparecen en más de la mitad de los pliegues durante la validación cruzada). Sin embargo, su selección como parte del proceso de análisis no respondió a la pregunta de cómo estas características y sus combinaciones se relacionan con la soledad. Por lo tanto, ejecutamos el algoritmo Apriori (soporte mínimo = 10% y confianza mínima = 90%) en estas características seleccionadas para extraer diferentes combinaciones de características de comportamiento que eran indicativas de soledad. La [Tabla 6](#) resume los patrones extraídos utilizando las características seleccionadas en cada análisis (detección posterior a la soledad y cambio en la soledad).

Como se muestra en la [Tabla 6](#), la baja frecuencia de uso del teléfono en ciertas horas durante el fin de semana y en las horas de la mañana, así como pasar menos tiempo fuera del campus y en lugares de eventos sociales por la tarde y la noche, se asociaron con el NS. Recuerde que el apoyo es el porcentaje de los patrones de comportamiento observados (columna izquierda en las [Tablas 6 y 7](#)) en todo el conjunto de datos (aquí el

población participante), mientras que la confianza es el porcentaje de muestras con ese patrón observado que satisfacen una determinada condición, por ejemplo, cambio en la soledad. Por ejemplo, se observa el patrón duración mínima de uso del teléfono [día laborable] = pasos bajos y mínimos en episodios activos [noche, fin de semana] = duración baja y duración mínima de episodios sedentarios [noche, fin de semana] = bajo (tercera fila en la [Tabla 6](#)) en el 31% de los participantes (apoyo) de los cuales el 92% (confianza) experimentó una disminución de la soledad al final del semestre.

Como la pregunta 14 en la escala de UCLA (sentimiento de aislamiento) estaba más asociada con la puntuación de soledad total (según nuestro análisis en secciones anteriores), también extrajimos patrones de comportamiento diario que estaban asociados con las puntuaciones de esa pregunta (sentimientos de aislamiento). ) utilizando el mismo conjunto de funciones seleccionadas. La [Tabla 7](#) muestra los patrones extraídos asociados con el sentimiento de aislamiento. Por ejemplo, los participantes con baja sensación de aislamiento pasan menos tiempo estudiando por la tarde los fines de semana y pasan una cantidad moderada de tiempo en zonas verdes por la mañana. Además, un mayor nivel general de actividad y pasos durante el día y la noche se asocia con una menor sensación de aislamiento.

Tabla 6. Patrones extraídos que muestran cómo las combinaciones de características de comportamiento seleccionadas por el algoritmo de aprendizaje automático se asocian con una alta soledad y una disminución de la soledad.

Patrón (características clasificadas en baja, moderada y alta)	possoledad
Frecuencia del primer desbloqueo de pantalla entre la 1 y las 2 p. m. [fin de semana] = baja y frecuencia del último bloqueo de pantalla entre las 10 y las 11 a. m. [mañana] = baja y tiempo de permanencia fuera del campus [tarde] [fin de semana] = tiempo de permanencia bajo y máximo en casas de eventos sociales [tarde][noche] [día laborable] = bajo	• Postsoledad = alta soledad • Apoyo = 17% • Confianza = 92%
Número de escaneos del dispositivo Bluetooth menos frecuente que pertenece a uno mismo o a otros [fin de semana, semana 2017-03-08] = bajo y número de escaneos del dispositivo Bluetooth menos frecuente que pertenece a otros [mañana, fin de semana, semana 2017-05-03 ] = alta y último bloqueo de pantalla entre las 10 y las 11 a. m. [mañana, día laborable, semana 2017-04-19] = baja y último bloqueo de pantalla entre las 2 y 3 p. m. [tarde, día laborable, semana 2017-02-01] [semana 2017 -03-15] [día laborable, semana 2017-03-15] = baja y hora en el grupo local 3 [tarde] [fin de semana, semana 2017-03-08] = baja y última pantalla entre las 3 y las 4 p.m. [semana 2017 -02-01] = baja y primera pantalla entre las 3 y las 4 am [noche] [día laborable, medio semestre 2017-03-01] = baja	• Postsoledad = alta soledad • Apoyo = 30% • Confianza = 90%
Duración mínima de uso del teléfono [día laborable] = pasos bajos y mínimos en episodios activos [noche, fin de semana] = duración baja y mínimo de episodios sedentarios [noche, fin de semana] = bajo	• Cambio = disminución de la soledad • Apoyo = 31% • Confianza = 92%
Último desbloqueo de pantalla entre las 2 y las 3 p. m. [tarde, semana 2017-03-29] = bajo y primera pantalla entre las 5 y 6 a. m. [día laborable, semana 2017-03-15] = bajo y último desbloqueo de pantalla entre la 1 y las 2 a. m. [medio semestre 2017-03-01] = duración baja y mínima de episodios sedentarios [mañana, día laborable] = baja y primer desbloqueo de pantalla entre las 5 y las 6 p.m. [semana 2017-02-08] = duración baja y mínima de sueño duración [fin de semana, medio semestre 2017-03-01] = baja	• Cambio = disminución de la soledad • Apoyo = 50% • Confianza = 90%

JMIR MEALTH Y UHEALTH		Doryab y otros	
Tabla 7. Patrones de comportamiento extraídos asociados al sentimiento de aislamiento.			
Patrón (características clasificadas en bajo, medio y alto)	UCLAa nivel 14	Soporte, % (soporte mínimo = 10%)	Confianza, % (confianza mínima = 90%)
Número de escaneos del dispositivo Bluetooth ajeno menos frecuente [mañana, fin de semana] = bajo y duración del estudio [tarde, fin de semana] = bajo y estancia mínima en áreas verdes [mañana] = moderada	Sensación de aislamiento 18 = bajo		92
Sueño total [mañana, semana 01-03-2017] = moderado y número de exploraciones de las menos frecuentes Dispositivo Bluetooth perteneciente a otros [tarde, fin de semana, semana 2017-02-01] [fin de semana, semana 2017-02-22] [tarde, día laborable, semana 2017-01-25] = moderado y número de escaneos del Bluetooth menos frecuente dispositivo [noche, día laborable, medio semestre 2017-03-01] [noche, semana 2017- 01-18] [noche, día laborable, medio semestre 2017-01-18] = baja y primer desbloqueo de pantalla entre las 10 y las 11 a. m. [día laborable , semana 2017-04-26] = bajo	Sensación de aislamiento 30 = bajo		90
Tiempo en ubicaciones frecuentes [tarde, día laborable] = bajo	Cambiar = de menor a mayor	28	92
Desbloqueo de la primera pantalla entre las 3 y las 4 a.m. [noche, fin de semana] = pasos bajos y promedio en episodios activos [mañana, fin de semana] = alto	Cambiar = de mayor a menor	28	92
Duración mínima del sueño [fin de semana, semana 2017-01-18] = moderado y número de escaneos del dispositivo Bluetooth menos frecuente [noche, día laborable, medio semestre 2017-03-01] [noche, día laborable, medio semestre 2017-01- 18] = baja y primera pantalla entre el mediodía y la 1 pm [tarde, fin de semana, semana 2017-04-26] = baja y primera pantalla entre las 7 y 8 am [día laborable, semana 2017-03-15] = baja y última bloqueo de pantalla entre medianoche y 1 a.m. [medio semestre 2017-03-01] = bajo y primera pantalla entre las 3 y 4 a.m. [noche, día laborable, semana 2017-03-08] = bajo	Cambiar = de mayor a menor	33	93

aUCLA: Universidad de California, Los Ángeles.

## Discusión

### Principales hallazgos y comparación con anteriores Investigación

Este estudio informó un análisis triple de la soledad entre estudiantes universitarios, explorando el potencial de los datos de detección recopilados pasivamente desde dispositivos móviles y portátiles para estimar la soledad e identificar características de datos de comportamiento asociadas con la soledad. Los resultados mostraron que las características de comportamiento detalladas extraídas de datos de series temporales de dispositivos móviles y portátiles pueden detectar niveles altos y bajos de soledad con alta precisión y que estas características pueden distinguir el comportamiento de los estudiantes con altos niveles de soledad de aquellos con bajos niveles de soledad. Por ejemplo, los resultados mostraron que los estudiantes con altos niveles de soledad pasan menos tiempo fuera del campus y socializan menos por las noches durante los fines de semana que los estudiantes con bajos niveles de soledad.

Ampliamos la investigación existente sobre el estudio de la soledad de cinco maneras. En primer lugar, recopilamos datos de comportamiento de una muestra sustancialmente grande (n=160) de estudiantes universitarios durante un período de 16 semanas, un período de tiempo más largo en comparación con el estado actual de la investigación [11,12,14]. Esto brindó la oportunidad de analizar el comportamiento a largo plazo asociado con la soledad a través de la minería de patrones y observar cambios en el comportamiento asociados con cambios en la soledad. En segundo lugar, extrajimos un conjunto mucho mayor de características de comportamiento de los datos sin procesar recopilados en teléfonos inteligentes y dispositivos portátiles (77,805 características) y mostramos su impacto en la detección del nivel de soledad y el nivel de cambio en la detección de la soledad. Las características proporcionaron una lente para observar patrones de comportamiento más detallados asociados con la soledad. En tercer lugar, por primera vez presentamos las asociaciones entre el nivel de soledad y la

combinaciones de características de comportamiento. Este análisis proporcionó un conjunto de patrones extraídos objetivamente que describían comportamientos asociados con la soledad. En cuarto lugar, además del nivel general de soledad, analizamos asociaciones entre los niveles de soledad y las respuestas a cada pregunta. Encontramos fuertes patrones de asociación entre las puntuaciones de soledad previas y posteriores y la pregunta de la escala de UCLA relacionada con los sentimientos de aislamiento. En consecuencia, analizamos las asociaciones entre las respuestas a esta pregunta y las características de comportamiento y descubrimos que un alto nivel de actividad y pasos durante el día y la noche se asociaban con una menor sensación de aislamiento. Estos resultados son importantes ya que pueden proporcionar mediciones objetivas de experiencias asociadas con diferentes dimensiones de la soledad (evaluadas mediante preguntas específicas en la escala de UCLA) en forma de características de comportamiento combinadas. Finalmente, mediante un análisis de aprendizaje automático, estimamos los niveles generales de soledad y el cambio en la soledad con una alta precisión del 80,2% y 88,4%, respectivamente. Aparte del estudio de Pulekar et al [11] que analizó 2 semanas de datos de 9 estudiantes usando un pequeño conjunto de funciones de teléfonos inteligentes únicamente y el estudio de Sanchez et al [12] que infirió diferentes tipos de soledad en 12 adultos mayores usando Tras una semana de datos móviles, no conocemos ningún estudio existente para detectar la soledad a partir de datos de detección pasiva longitudinal mediante aprendizaje automático.

Nuestra muestra de estudiantes universitarios obtuvo puntuaciones HL, consistentes con el último índice de soledad de EE. UU. [2], lo que sugiere que este grupo de edad experimentó la mayor soledad de todas las generaciones encuestadas. También descubrimos que el sentimiento de aislamiento era un indicador fuerte y consistente de soledad en las encuestas anteriores y posteriores al semestre. La sensación de que nadie te conoce realmente fue un indicador más fuerte en la encuesta presemestral. Esto puede ser el resultado de que los estudiantes universitarios de primer año todavía intentan formar vínculos con sus compañeros de clase. Por otra parte, las relaciones carentes de significado

se asoció fuertemente con las puntuaciones de soledad posteriores al semestre, lo que podría indicar que los estudiantes no tenían relaciones significativas con sus compañeros. Aunque extraer estas asociaciones es un enfoque novedoso y las observaciones son interesantes, se deben realizar análisis futuros en conjuntos de datos similares para confirmar estos resultados.

Extrajimos un rico conjunto de funciones diarias del teléfono inteligente y Fitbit que reflejan patrones de actividad y movilidad, comunicación, sueño y uso del teléfono. También generamos un conjunto de características agregadas a nivel semestral.

Utilizamos estos conjuntos de características en un proceso de aprendizaje automático para inferir niveles de soledad y cambios en las puntuaciones de soledad. Entrenamos y evaluamos un clasificador de conjunto mediante una validación cruzada de dejar a un estudiante fuera para explorar con qué precisión se podría estimar el nivel de soledad post-semestre, así como el cambio en las puntuaciones de soledad, a partir de características de comportamiento pasivo. Se informaron los resultados promedio de la validación cruzada para cada resultado. Incluimos la selección de características como parte del proceso de capacitación para adquirir un conjunto de características de comportamiento que fueron seleccionadas repetidamente como impactantes para la mayoría de los estudiantes. Nuestro análisis mostró que las características de comportamiento más detalladas fueron mejores para identificar el nivel general de soledad (80,2% de precisión), mientras que las características agregadas a nivel semestral distinguieron mejor el nivel de cambio (88,4% de precisión). Aunque la mayor precisión lograda con las características de todas las épocas fue modesta considerando la gran cantidad de características utilizadas en el proceso, el análisis proporcionó un conjunto de características que podrían usarse para extraer patrones de asociación detallados de soledad semana a semana. .

Nuestro enfoque de extracción de patrones, utilizando las funciones seleccionadas, mostró que los patrones y horarios de uso del teléfono, combinados con pasar menos tiempo fuera del campus y en lugares de eventos sociales durante las tardes los fines de semana, eran más indicativos de NS en estudiantes universitarios. También mostró que un menor uso del teléfono y una menor actividad después de la medianoche se asociaban con una disminución de la soledad al final del semestre. Además de un menor uso del teléfono durante las horas nocturnas, descubrimos que un alto nivel de actividad (especialmente en las horas de la mañana), menos tiempo estudiando los fines de semana y pasar más tiempo en áreas verdes se asociaban con una sensación de menos aislamiento. Estos hallazgos son consistentes con los resultados del estudio de Wang et al [14] que encontró correlaciones negativas entre la soledad y la duración de la actividad durante el día y la noche. Sin embargo, hasta donde sabemos, este es el primer estudio que informa sobre combinaciones de características de comportamiento observadas en una población de estudio.

## Limitaciones

Este estudio proporciona información sobre cómo comprender la soledad a través de características de comportamiento pasivo. Sin embargo, tiene una serie de limitaciones. Primero, aunque elegimos deliberadamente a estudiantes universitarios como participantes de nuestro estudio, es posible que nuestros resultados solo se generalicen a esta población. En segundo lugar, a pesar de la duración de un semestre de este estudio (que es considerablemente más larga que la mayoría de las investigaciones existentes sobre la soledad), los estudios con períodos de recopilación de datos a más largo plazo pueden revelar patrones adicionales de comportamiento que no pudieron observarse en un semestre. Aunque nuestros análisis proporcionan ideas novedosas e interesantes para comprender el comportamiento de la soledad a través de una lente objetiva

de la detección pasiva, se necesitan más análisis sobre el mismo tipo de datos para proporcionar evidencia suficiente para la generalización de nuestros resultados. En tercer lugar, los problemas técnicos provocaron que faltaran una gran cantidad de datos de muchos participantes que tuvieron que eliminarse del análisis de aprendizaje automático, lo que redujo considerablemente el tamaño del conjunto de datos. Aunque los datos faltantes son un problema común en el análisis de datos, una planificación más cuidadosa y conservadora y un software más estable pueden reducir el riesgo de que falten. Cuarto, como no pudimos encontrar métodos bien conocidos en la literatura para elegir nuestros umbrales (por ejemplo, la puntuación límite para indicar el nivel de soledad o el número de pasos para identificar episodios de actividad), tomamos esas decisiones consultando con los psicólogos. en nuestro equipo. Entendemos que diferentes umbrales pueden proporcionar resultados diferentes. Sin embargo, nuestro objetivo en este estudio no fue encontrar los umbrales óptimos sino comprender la experiencia de soledad en estudiantes universitarios y explorar la viabilidad de utilizar sensores pasivos para detectar la soledad y los patrones de comportamiento asociados con ella. Quinto, aunque se indicó a los estudiantes que usaran el Fitbit en su mano no dominante, debido a la naturaleza de nuestro estudio que recopila datos en la naturaleza, no teníamos mucho control sobre la forma en que los estudiantes usaban el Fitbit ni pudimos rastrear si el Fitbit se usaba o no. Fitbit estaba usado o cargado. Reconocemos que estos factores pueden afectar las mediciones relacionadas con las actividades y el sueño. Sin embargo, este es un desafío técnico al que nos enfrentamos con la recopilación de datos en la naturaleza y estamos trabajando en el desarrollo de soluciones que proporcionen una estimación precisa de la actividad del usuario a pesar de las variaciones en sus patrones de uso. Finalmente, desarrollamos un canal de aprendizaje automático que podría manejar una gran cantidad de funciones, seleccionar un conjunto estable de funciones y utilizarlas en el proceso de capacitación y validación. Por primera vez, también mostramos el potencial del uso de la minería de datos para explorar la combinación de características de comportamiento asociadas con un resultado de salud. La comunidad investigadora puede adaptar el proceso desarrollado y nuestro enfoque de extracción de datos como un marco genérico para estudios que evalúen otros resultados. Sin embargo, reconocemos que los resultados obtenidos a través del proceso y Apriori dependen en gran medida de la configuración de los parámetros y los pasos de procesamiento, y los resultados pueden variar con diferentes datos y conjuntos de características.

Planeamos avanzar en nuestro proceso de aprendizaje automático para probar diferentes algoritmos de aprendizaje y selección de funciones y encontrar automáticamente los parámetros optimizados. Nuestros planes futuros giran en torno a abordar algunas de las limitaciones anteriores, incluido un establecimiento de umbrales más sistemático tanto para la extracción de características como para la medida de resultados (nivel de soledad). Planeamos experimentar con múltiples categorías y umbrales en estudios futuros. También planeamos agregar más análisis para estudiar la relación entre la soledad, la depresión, el estrés y otros resultados de salud mental.

## Conclusiones

Nuestros hallazgos resaltan la viabilidad de utilizar teléfonos inteligentes ubicuos y sensores portátiles para detectar pasivamente la soledad en estudiantes universitarios e identificar los patrones de comportamiento asociados con la soledad. Los hallazgos sugieren un enfoque para sentir pasivamente la soledad y brindar oportunidades que podrían reducir la soledad, por ejemplo, notificando a familiares y amigos para que brinden apoyo social, conectando a los

persona con personas similares, o recomendar actividades, como salir del campus, pasar tiempo en áreas verdes o asistir a eventos sociales de interés. Intervenciones constructivas basadas en

Los hallazgos empíricos sobre la experiencia de la soledad podrían afectar significativamente el bienestar de los estudiantes.

#### Agradecimientos Este

material se basa en el trabajo apoyado por la Fundación Nacional de Ciencias bajo el número de subvención IIS1816687 y la Universidad Carnegie Mellon.

#### Conflictos de interés

Ninguno declarado.

#### Apéndice multimedia 1 Lista de

características semestrales que se seleccionaron en nuestro modelo para más de la mitad de los pliegues durante la validación cruzada.

[\[Archivo PDF \(archivo Adobe PDF\), 97KB-Apéndice multimedia 1\]](#)

#### Referencias

- Cacioppo JT, Patrick W. Soledad: la naturaleza humana y la necesidad de conexión social. Nueva York: WW Norton & Compañía; 2008.
- MultiVu: Producción Multimedia y Distribución Estratégica. 2018. La mayoría de los estadounidenses son considerados solitarios URL: <https://tinyurl.com/yxguwkk3>
- Perlman D, Peplau LA. Hacia una psicología social de la soledad. Pers Relatsh 1981;3:31-56. [doi: [10.4236/psic.2017.810105](https://doi.org/10.4236/psic.2017.810105)]
- Cacioppo JT, Cacioppo S, Boomsma DI. Mecanismos evolutivos de la soledad. Cogn Emot 2014;28(1):3-21 [GRATIS Texto completo] [doi: [10.1080/02699931.2013.837379](https://doi.org/10.1080/02699931.2013.837379)] [Medline: [24067110](https://pubmed.ncbi.nlm.nih.gov/24067110/)]
- Masi CM, Chen HY, Hawkey LC, Cacioppo JT. Un metaanálisis de intervenciones para reducir la soledad. Pers Soc Psychol Rev 2011 Aug;15(3):219-266 [Texto completo GRATIS] [doi: [10.1177/1088868310377394](https://doi.org/10.1177/1088868310377394)] [Medline: [20716644](https://pubmed.ncbi.nlm.nih.gov/20716644/)]
- Tan C, Pamuk M, Dönder A. Soledad y teléfono móvil. Procedia Soc Behav Sci 2013;103:606-611. [doi: [10.1016/j.sbspro.2013.10.378](https://doi.org/10.1016/j.sbspro.2013.10.378)]
- Hagerty BM, Williams RA. Los efectos del sentido de pertenencia, el apoyo social, el conflicto y la soledad en la depresión. enfermeras Res 1999;48(4):215-219. [doi: [10.1097/00006199-199907000-00004](https://doi.org/10.1097/00006199-199907000-00004)] [Medline: [10414684](https://pubmed.ncbi.nlm.nih.gov/10414684/)]
- House JS, Landis KR, Umberson D. Relaciones sociales y salud. Ciencia 29 de julio de 1988; 241 (4865): 540-545. [doi: [10.1126/ciencia.3399889](https://doi.org/10.1126/ciencia.3399889)] [Medline: [3399889](https://pubmed.ncbi.nlm.nih.gov/3399889/)]
- Holt-Lunstad J, Smith TB, Layton JB. Relaciones sociales y riesgo de mortalidad: una revisión metaanalítica. PLoS Med 2010 julio 27;7(7):e1000316 [Texto completo GRATIS] [doi: [10.1371/journal.pmed.1000316](https://doi.org/10.1371/journal.pmed.1000316)] [Medline: [20686659](https://pubmed.ncbi.nlm.nih.gov/20686659/)]
- Holt-Lunstad J, Smith TB, Baker M, Harris T, Stephenson D. La soledad y el aislamiento social como factores de riesgo de mortalidad: una revisión metaanalítica. Perspect Psychol Sci, marzo de 2015; 10 (2): 227-237. [doi: [10.1177/1745691614568352](https://doi.org/10.1177/1745691614568352)] [Medline: [25910392](https://pubmed.ncbi.nlm.nih.gov/25910392/)]
- Pulekar G, Agu E. Detección autónoma de la soledad y sus interacciones con los rasgos de personalidad mediante el uso de teléfonos inteligentes. En: Actas de la Conferencia sobre tecnologías de punto de atención de innovación sanitaria. 2016 Presentado en: IEEE'16; 9 al 11 de noviembre de 2016; Cancún, México pág. 134-137. [doi: [10.1109/HIC.2016.7797715](https://doi.org/10.1109/HIC.2016.7797715)]
- Sánchez W, Rebollar AM, Campos W, Esquivel HE, Pelechano V. Inferir niveles de soledad en adultos mayores a partir de teléfonos inteligentes. J Ambient Intell Smart Environ 2015;7(1):85-98. [doi: [10.3233/AIS-140297](https://doi.org/10.3233/AIS-140297)]
- Ben-Zeev D, Scherer EA, Wang R, Xie H, Campbell AT. Evaluación psiquiátrica de próxima generación: uso de sensores de teléfonos inteligentes para monitorear el comportamiento y la salud mental. Psychiatr Rehabil J 2015 Sep;38(3):218-226 [Texto completo GRATIS] [doi: [10.1037/prj0000130](https://doi.org/10.1037/prj0000130)] [Medline: [25844912](https://pubmed.ncbi.nlm.nih.gov/25844912/)]
- Wang R, Chen F, Chen Z, Li T, Harari G, Tignor S, et al. StudentLife: Evaluación de la salud mental, el rendimiento académico y las tendencias de comportamiento de los estudiantes universitarios que utilizan teléfonos inteligentes. En: Actas de la Conferencia Conjunta Internacional ACM de 2014 sobre Computación Generalizada y Ubicua. 2014 Presentado en: UbiComp'14; 13 al 17 de septiembre de 2014; Seattle, Washington pág. 3-14. [doi: [10.1145/2632048.2632054](https://doi.org/10.1145/2632048.2632054)]
- Gao Y, Li A, Zhu T, Liu X, Liu X. Cómo se correlaciona el uso de teléfonos inteligentes con la ansiedad social y la soledad. PeerJ 2016;4:e2197 [Texto completo gratis] [doi: [10.7717/peerj.2197](https://doi.org/10.7717/peerj.2197)] [Medline: [27478700](https://pubmed.ncbi.nlm.nih.gov/27478700/)]
- Feehan LM, Goldman J, Sayre EC, Park C, Ezzat AM, Yoo JY, et al. Precisión de los dispositivos FitBit: revisión sistemática y síntesis narrativa de datos cuantitativos. JMIR Mhealth Uhealth 2018 9 de agosto;6(8):e10527 [Texto completo GRATIS] [doi: [10.2196/10527](https://doi.org/10.2196/10527)] [Medline: [30093371](https://pubmed.ncbi.nlm.nih.gov/30093371/)]
- [ PubMed ] 17. Ferreira D, Kostakos V, Dey AK. AWARE: un marco de instrumentación de contexto móvil. Frente TIC 2015 20 Abr;2:6. [doi: [10.3389/ficción.2015.00006](https://doi.org/10.3389/ficción.2015.00006)]

18. Russell DW. Escala de soledad de UCLA (versión 3): confiabilidad, validez y estructura factorial. J Pers Assess, febrero de 1996; 66 (1): 20-40. [doi: [10.1207/s15327752jpa6601\\_2](https://doi.org/10.1207/s15327752jpa6601_2)] [Medline: [8576833](https://pubmed.ncbi.nlm.nih.gov/8576833/)]
19. Agrawal R, Imielinski T, Swami A. Reglas de asociación minera entre conjuntos de elementos en grandes bases de datos. En: Buneman P, Jajodia S, editores. Actas de la Conferencia Internacional ACM SIGMOD de 1993 sobre Gestión de Datos. Ciudad de Nueva York: ACM Press; 1993:207-216.
20. Han J, Pej J, Kamber M. Minería de datos: conceptos y técnicas. Ámsterdam, Países Bajos: Elsevier; 2011.
21. Doryab A, Chikersal P, Liu X, Dey AK. ArXiv. 2018. Extracción de características de comportamiento de teléfonos inteligentes y URL de datos portátiles: <https://arxiv.org/pdf/1812.10394.pdf> 22. Saeb S, Zhang M.
- Karr CJ, Schueller SM, Corden ME, Kording KP, et al. El sensor del teléfono móvil se correlaciona con la depresión Gravedad de los síntomas en el comportamiento de la vida diaria: un estudio exploratorio. J Med Internet Res 2015 15 de julio; 17 (7): [e175](https://doi.org/10.2196/jmir.4273) [Texto completo GRATIS] [doi: [10.2196/jmir.4273](https://doi.org/10.2196/jmir.4273)] [Medline: [26180009](https://pubmed.ncbi.nlm.nih.gov/26180009/)]
23. Presione WH, Rybicki GB. Algoritmo rápido para análisis espectral de datos muestreados de manera desigual. Astrophis J, marzo de 1989; 338: 277-280. [doi: [10.1086/167197](https://doi.org/10.1086/167197)]
24. Ester M, Kriegel HP, Sander J, Xu X. Un algoritmo basado en densidad para descubrir clústeres en grandes bases de datos espaciales con ruido. En: Actas de la Segunda Conferencia Internacional sobre Descubrimiento de Conocimiento y Minería de Datos. 1996 Presentado en: KDD'96; 2 al 4 de agosto de 1996; Portland, Oregón pag. 226-231 URL : <https://www.aaai.org/Papers/KDD/1996/KDD96-037.pdf>
25. Canzian L, Musolesi M. Trayectorias de la depresión: seguimiento discreto de los estados depresivos mediante el análisis de rastros de movilidad de teléfonos inteligentes. En: Actas de la Conferencia Conjunta Internacional ACM de 2015 sobre Computación Generalizada y Ubicua. 2015 Presentado en: UbiComp'15; 7 al 11 de septiembre de 2015; Osaka, Japón pag. 1293-1304. [doi: [10.1145/2750858.2805845](https://doi.org/10.1145/2750858.2805845)]
26. Bae S, Dey AK, Baja CA. Uso del comportamiento sedentario recopilado pasivamente para predecir el reingreso hospitalario. En: Actas de la Conferencia Conjunta Internacional ACM de 2016 sobre Computación Generalizada y Ubicua. 2016 Presentado en: UbiComp'16; 12 al 16 de septiembre de 2016; Heidelberg, Alemania pag. 616-621. [doi: [10.1145/2971648.2971750](https://doi.org/10.1145/2971648.2971750)]
27. Fonti V, Belitser E. Semantic Scholar. 2017. Selección de funciones mediante Lasso URL: <https://pdfs.semanticscholar.org/24ac/d159910658223209433cf4cbe3414264de39.pdf> 28.
- Meinshausen N, Bühlmann P. Selección de estabilidad. Método estadístico JR Stat Soc Serie B 2010;72(4):417-473. [doi: [10.2307/40802220](https://doi.org/10.2307/40802220)]
29. Wang R, Wang W, daSilva A, Huckins JF, Kelley WM, Heatherton TF, et al. Seguimiento de la dinámica de la depresión en estudiantes universitarios que utilizan teléfonos móviles y sensores portátiles. En: Actas de la ACM sobre tecnologías interactivas, móviles, portátiles y ubicuas. 2018 Presentado en: UbiComp'18; 9 al 11 de octubre de 2018; Singapur pag. 1-26. [doi: [10.1145/3191775](https://doi.org/10.1145/3191775)]

## Abreviaturas

API: interfaz de programación de aplicaciones  
 DBSCAN: agrupación espacial basada en densidad de aplicaciones con ruido  
 DL: disminución de la soledad  
 FEC: componente de extracción de características  
 GPS: sistema de posicionamiento global  
 HL: alta soledad  
 DNI: documento de identidad  
 IL: mayor soledad  
 LASSO: operador de selección y contracción mínima absoluta  
 LL: baja soledad  
 NRLR: regresión logística aleatoria anidada  
 SMS: servicio de mensajes cortos  
 UCLA: Universidad de California, Los Ángeles  
 UL: soledad sin cambios



Editado por A Tsanas; presentado el 20.12.18; revisado por pares A Triantafyllidis, J Di, L Pan; comentarios al autor 29.01.19; versión revisada recibida el 13.05.19; aceptado el 13.06.19; publicado el 24.07.19

Por favor citar

como: Doryab A, Villalba DK, Chikersal P, Dutcher JM, Tumminia M, Liu X, Cohen S, Creswell K, Mankoff J, Creswell JD, Dey AK Identificación de fenotipos conductuales de soledad y aislamiento social con detección pasiva: análisis estadístico , Minería de datos y aprendizaje automático de datos de teléfonos inteligentes y Fitbit JMIR Mhealth Uhealth 2019;7(7):e13209 URL: <http://mhealth.jmir.org/2019/7/e13209/> doi: [10.2196/13209](https://doi.org/10.2196/13209)

PMID: [31342903](https://pubmed.ncbi.nlm.nih.gov/31342903/)

©Afsaneh Doryab, Daniella K Villalba, Perna Chikersal, Janine M Dutcher, Michael Tumminia, Xinwen Liu, Sheldon Cohen, Kasey Creswell, Jennifer Mankoff, John D Creswell, Anind K Dey. Publicado originalmente en JMIR Mhealth y Uhealth (<http://mhealth.jmir.org>), 24.07.2019. Este es un artículo de acceso abierto distribuido bajo los términos de la Licencia de Atribución Creative Commons (<https://creativecommons.org/licenses/by/4.0/>), que permite el uso, distribución y reproducción sin restricciones en cualquier medio, siempre que el original El trabajo, publicado por primera vez en JMIR mhealth y uhealth, está debidamente citado. Se debe incluir la información bibliográfica completa, un enlace a la publicación original en <http://mhealth.jmir.org/>, así como esta información de derechos de autor y licencia.